

# Základy pravděpodobnosti a matematické statistiky

## 11. Analýza rozptylu




# 11. Analýza rozptylu

## Srovnání více náhodných veličin

**Příklad:** Chceme porovnat kvalitu vláken dodávaných třemi různými výrobci.  
Jako kritérium kvality je zvolena pevnost vláken v tahu.

$$X_1^1, X_2^1, \dots, X_{n_1}^1, \quad X_1^2, X_2^2, \dots, X_{n_2}^2, \quad X_1^3, X_2^3, \dots, X_{n_3}^3,$$



nulová hypotéza

$$H_0: \mu_1 = \mu_2 = \mu_3$$

alternativní hypotéza

$$H_A: \mu_i \neq \mu_j \text{ pro některou dvojici } i, j \text{ (oboustranná)}$$

hladina významnosti

$$\alpha = 5\%$$

Jedna z možností je provést  $k(k-1)/2$  porovnání pomocí dvouvýběrových testů.

ALE: tím se výrazně zvýší hladina významnosti.

## Srovnání více náhodných veličin

**Příklad:** Chceme porovnat kvalitu vláken dodávaných třemi různými výrobci.  
Jako kritérium kvality je zvolena pevnost vláken v tahu.

$$X_1^1, X_2^1, \dots, X_{n_1}^1, \quad X_1^2, X_2^2, \dots, X_{n_2}^2, \quad X_1^3, X_2^3, \dots, X_{n_3}^3,$$


		hladina významnosti v <i>t</i> -testu					
		0,20	0,10	0,05	0,02	0,01	0,001
nulová hypotéza	počet porovnávání <i>k</i>	0,20	0,10	0,05	0,02	0,01	0,001
	2	0,20	0,10	0,05	0,02	0,01	0,001
	3	0,41	0,23	0,13	0,05	0,03	0,003
	4	0,58	0,36	0,21	0,09	0,05	0,006
	5	0,71	0,47	0,23	0,13	0,07	0,009
	10	0,96	0,83	0,63	0,37	0,23	0,034
	20	1,00	0,98	0,92	0,71	0,52	0,109
alternativní hypotéza	$\infty$	1,00	1,00	1,00	1,00	1,00	1,000

Jedna z možností je provést  $k(k-1)/2$  porovnání pomocí dvouvýběrových testů.  
**ALE:** tím se výrazně zvýší hladina významnosti.


Tedy je třeba provádět tzv. simultánní test.

# Metoda ANOVA pro srovnání více náhodných veličin

Rozptyl mezi skupinami je **velký** vzhledem k součtu rozptylů uvnitř skupin => střední hodnoty **jsou různé** => nulovou hypotézu **zamítáme**



Rozptyl mezi skupinami je **malý** vzhledem k součtu rozptylů uvnitř skupin => střední hodnoty lze považovat **za nerozlišitelné** => nulovou hypotézu **nelze zamítnout**




# Metoda ANOVA pro srovnání více náhodných veličin

**ANalysis Of VAriance = ANOVA**

pro 1 faktor = všechna data rozdělíme do skupin podle jednoho hlediska (úrovní jednoho faktoru)

k úrovní = k skupin  
v každé skupině n měření



1) celkový průměr všech naměřených hodnot:  $\bar{y} = \frac{1}{n.k} \sum_{i=1}^k \sum_{j=1}^n y_{ij}$

2) průměry v jednotlivých skupinách:  $\bar{y}_i = \frac{1}{n} \sum_{j=1}^n y_{ij}$

3) celkový součet čtvercových odchylek:  $SS_T = \sum_{i=1}^k \sum_{j=1}^n (y_{ij} - \bar{y})^2$

4) součet čtvercových odchylek uvnitř skupin

$$SS_E = \sum_{i=1}^k \sum_{j=1}^n (y_{ij} - \bar{y}_i)^2$$

5) součet čtvercových odchylek mezi skupinami

$$SS_F = n \sum_{i=1}^k (\bar{y}_i - \bar{y})^2$$

# Metoda ANOVA pro srovnání více náhodných veličin

Tabulka analýzy rozptylu:


Zdroj variability	Součet čtverců	Stupně volnosti	Průměrný čtverec	Testová statistika	p-hodnota
faktor (mezi skupinami)	$SS_F$	$k-1$	$MS_F = \frac{SS_F}{k-1}$	$F = \frac{MS_F}{MS_E}$	
rezidua (uvnitř skupin)	$SS_E$	$k(n-1)$	$MS_E = \frac{SS_E}{k(n-1)}$		
celkový	$SS_T$	$kn-1$			

Testová statistika  $F = \frac{\frac{SS_F}{k-1}}{\frac{SS_E}{k(n-1)}} = \frac{MS_F}{MS_E}$  má Fisherovo-Snedecorovo rozdělení o  $(k-1)$  a  $k(n-1)$  stupních volnosti.

# Metoda ANOVA pro srovnání více náhodných veličin

**Příklad:** Chceme porovnat kvalitu vláken dodávaných třemi různými výrobci.  
Jako kritérium kvality je zvolena pevnost vláken v tahu.

$$X_1^1, X_2^1, \dots, X_{n_1}^1, \quad X_1^2, X_2^2, \dots, X_{n_2}^2, \quad X_1^3, X_2^3, \dots, X_{n_3}^3,$$



```
> pvl <- data.frame(read.table("pevnost_vlaken.txt", header=T))
> boxplot(pevnost~dodavatel, data=pvl)
```

# Metoda ANOVA pro srovnání více náhodných veličin

**Příklad:** Chceme porovnat kvalitu vláken dodávaných třemi různými výrobci.  
Jako kritérium kvality je zvolena pevnost vláken v tahu.

$$X_1^1, X_2^1, \dots, X_{n_1}^1, \quad X_1^2, X_2^2, \dots, X_{n_2}^2, \quad X_1^3, X_2^3, \dots, X_{n_3}^3,$$

```
> oneway <- aov(pevnost~dodavatel, data=pvl)
> summary(oneway)
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
dodavatel	2	26.23	13.117	13.62	0.000425 ***
Residuals	15	14.45	0.963		
Total	17	40.68			

Signif. codes: 0 ‘\*\*\*’ 0.001 ‘\*\*’ 0.01 ‘\*’ 0.05 ‘.’ 0.1 ‘ ’ 1

**Závěr: nulovou hypotézu zamítáme. Pevnost vláken různých dodavatelů se statisticky významně liší.**


**Jak se liší dodavatelé mezi sebou?**

**Pokud zamítneme nulovou hypotézu v ANOVA, měli bychom provést tzv. Mnohonásobné porovnání**

# Metoda ANOVA pro srovnání více náhodných veličin

**Příklad:** Chceme porovnat kvalitu vláken dodávaných třemi různými výrobci.  
Jako kritérium kvality je zvolena pevnost vláken v tahu.

$$X_1^1, X_2^1, \dots, X_{n_1}^1, \quad X_1^2, X_2^2, \dots, X_{n_2}^2, \quad X_1^3, X_2^3, \dots, X_{n_3}^3,$$



Jak se liší dodavatelé mezi sebou?

Pokud zamítneme nulovou hypotézu v ANOVA, měli bychom provést tzv.  
Mnohonásobné porovnání

# Metoda ANOVA pro srovnání více náhodných veličin

## Metody mnohonásobného srovnávání:

- Tukeyova metoda
- Scheffého metoda
- Bonferroniho metoda
- Duncanova metoda
- ...

$$T = \frac{|\hat{\mu}_i - \hat{\mu}_j|}{S_*}, \quad i, j = 1, 2, \dots, k, \quad i \neq j$$

> `TukeyHSD(oneway, conf.level = .95)`

Tukey multiple comparisons of means  
95% family-wise confidence level


Fit: `aov(formula = pevnost ~ dodavatel, data = pvl)`

\$dodavatel

	diff	lwr	upr	p adj
b-a	0.4333333	-1.0385665	1.905233	0.7296030
c-a	2.7500000	1.2781002	4.221900	0.0005817
c-b	2.3166667	0.8447669	3.788566	0.0026211

=> z tabulky  $p$ -hodnot při porovnání po dvojicích vyplývá, že

- a ~ b jsou nerozlišitelné
- c ~ a se liší
- c ~ b se liší




Dodavatele 1 a 2 nelze statisticky odlišit, dodavatel 3 je významně lepší (jeho výkona dosahují statisticky významně vyšší pevnosti než od dodavatelů 1 a 2).

# Metoda ANOVA pro srovnání více náhodných veličin

## Metody mnohonásobného srovnávání:

- Tukeyova metoda
- Scheffého metoda
- Bonferroniho metoda
- Duncanova metoda
- ...

$$T = \frac{|\hat{\mu}_i - \hat{\mu}_j|}{S_*}, \quad i, j = 1, 2, \dots, k, \quad i \neq j$$



```
> pairwise.t.test(pvl$pevnost, pvl$dodavatel, p.adj = "bonf")
```

Pairwise comparisons using t tests with pooled SD

data: pvl\$pevnost and pvl\$dodavatel

	a	b
b	1.00000	-
c	0.00063	0.00291

P value adjustment method: bonferroni

=> z tabulky  $p$ -hodnot při porovnání po dvojicích vyplývá, že  
- a s b jsou nerozlišitelné  
- c se liší jak od a, tak i od b

# Metoda ANOVA pro srovnání více náhodných veličin

## Metody mnohonásobného srovnávání:

- Tukeyova metoda

$$Q = \frac{|\hat{\mu}_i - \hat{\mu}_j|}{S_*}, \quad S_* = \sqrt{\frac{S_E}{n(N-k)}}$$

označme  $k$  počet tříd a  $N = \sum_{i=1}^k n_i$

- musí být  $n_1 = n_2 = \dots = n_k$

$$Q < q_{1-\alpha}(k, N-k)$$

- Scheffého metoda

$$S = \frac{|\hat{\mu}_i - \hat{\mu}_j|}{S_*}, \quad S_* = \sqrt{\frac{S_E}{N-k}(k-1)\left(\frac{1}{n_i} + \frac{1}{n_j}\right)}$$

$$S < \sqrt{F_{1-\alpha}(k-1, N-k)}$$

- Bonferronihho metoda

$$T = \frac{|\hat{\mu}_i - \hat{\mu}_j|}{S_*}, \quad S_* = \sqrt{\frac{S_E}{N-k}\left(\frac{1}{n_i} + \frac{1}{n_j}\right)}$$

$$T < t_{1-\alpha/2}(N-k)$$

# **Metoda ANOVA pro srovnání více náhodných veličin**

## **Ověření podmínek pro použití ANOVA**

- Reprezentativnost výběru, náhodnost
- Nezávislost pozorování
- Normalita dat
- Stejné rozptyly (homoskedasticita)

# Vícenásobná ANOVA

## One-way ANOVA

- Zatím jsme měli datový soubor, který bylo možné roztrídit do několika skupin podle hodnoty jednoho faktoru **jednoduché třídění**

**Příklad:** pevnost vláken ~ dodavatel ( $a, b, c$ )

výkon ~ stroj (A1, A2)

- V mnoha případech se data dají roztrídit podle více faktorů

## Multi-way ANOVA

## vícenásobné třídění

**Příklad:** výnos plodiny ~ druh hnojiva + typ půdy

varianta	Výnos kukurice na parcele číslo							
	1	2	3	4	5	6	7	8
V1	1,29	1,19	1,23	1,33	1,27	1,29	1,31	1,2
V2	1,3	1,33	1,29	1,37	1,35	1,25	1,38	1,29
V3	1,2	1,24	1,25	1,24	1,2	1,21	1,28	1,17
V4	1,03	1,14	1,09	1,2	1,07	1,19	1,01	1,05

	pevnost	dodavatel
1	18.3	a
2	17.5	a
3	20.3	a
4	19.9	a
5	19.8	a
6	18.7	a
7	18.3	b
8	18.6	b
9	19.2	b
10	19.7	b
11	21.1	b
12	20.2	b
13	21.0	c
14	21.4	c
15	21.2	c
16	22.2	c
17	23.1	c
18	22.1	c


# Vícenásobná ANOVA

Příklad: výnos plodiny ~ druh hnojiva + typ půdy

varianta	Výnos kukuřice na parcele číslo								průměry
	1	2	3	4	5	6	7	8	
V1	1,29	1,19	1,23	1,33	1,27	1,29	1,31	1,2	1,26375
V2	1,3	1,33	1,29	1,37	1,35	1,25	1,38	1,29	1,32
V3	1,2	1,24	1,25	1,24	1,2	1,21	1,28	1,17	1,22375
V4	1,03	1,14	1,09	1,2	1,07	1,19	1,01	1,05	1,0975
průměry	1,205	1,225	1,215	1,285	1,2225	1,235	1,245	1,1775	1,22625

Je výnos kukuřice závislý na variantě, typu půdy nebo na obojím?

32 naměřených hodnot můžeme rozdělit



do 4 skupin po 8 podle varianty

dvojně třídění

do 8 skupin po 4 podle parcely

$$X = \mu_0 + \alpha_1 V_1 + \alpha_2 V_2 + \alpha_3 V_3 + \alpha_4 V_4 + \epsilon$$

$$H_0 : \alpha_1 = \alpha_2 = \alpha_3 = \alpha_4 = 0$$

$$H_A : \exists i : \alpha_i \neq 0$$

$$H_0 : \mu_{V_1} = \mu_{V_2} = \mu_{V_3} = \mu_{V_4} = \mu_0$$

$$H_A : \exists i, j : \mu_{V_i} \neq \mu_{V_j}$$

model1 = vynos ~ varianta

# Vícenásobná ANOVA

Příklad: výnos plodiny ~ druh hnojiva + typ půdy

	Výnos kukuřice na parcele číslo								
varianta	1	2	3	4	5	6	7	8	průměry
V1	1,29	1,19	1,23	1,33	1,27	1,29	1,31	1,2	1,26375
V2	1,3	1,33	1,29	1,37	1,35	1,25	1,38	1,29	1,32
V3	1,2	1,24	1,25	1,24	1,2	1,21	1,28	1,17	1,22375
V4	1,03	1,14	1,09	1,2	1,07	1,19	1,01	1,05	1,0975
průměry	1,205	1,225	1,215	1,285	1,2225	1,235	1,245	1,1775	1,22625

Je výnos kukuřice závislý na variantě, typu půdy nebo na obojím?

32 naměřených hodnot můžeme rozdělit

do 4 skupin po 8 podle varianty  
do 8 skupin po 4 podle parcely

dvojně třídění

$$X = \mu_0 + \beta_1 P_1 + \beta_2 P_2 + \beta_3 P_3 + \beta_4 P_4 + \beta_5 P_5 + \beta_6 P_6 + \beta_7 P_7 + \beta_8 P_8 + \epsilon$$

$$H_0 : \beta_1 = \dots = \beta_8 = 0$$

$$H_A : \exists j : \beta_j \neq 0$$

$$H_0 : \mu_{P_1} = \dots = \mu_{P_8} = \mu_0$$

$$H_A : \exists i, j : \mu_{P_i} \neq \mu_{P_j}$$

model2 = vynos ~ parcela

# Vícenásobná ANOVA

Příklad: výnos plodiny ~ druh hnojiva + typ půdy

varianta	Výnos kukuřice na parcele číslo								průměry
	1	2	3	4	5	6	7	8	
V1	1,29	1,19	1,23	1,33	1,27	1,29	1,31	1,2	1,26375
V2	1,3	1,33	1,29	1,37	1,35	1,25	1,38	1,29	1,32
V3	1,2	1,24	1,25	1,24	1,2	1,21	1,28	1,17	1,22375
V4	1,03	1,14	1,09	1,2	1,07	1,19	1,01	1,05	1,0975
průměry	1,205	1,225	1,215	1,285	1,2225	1,235	1,245	1,1775	1,22625

Je výnos kukuřice závislý na variantě, typu půdy nebo na obojím?

32 naměřených hodnot můžeme rozdělit

do 4 skupin po 8 podle varianty

dvojně třídění

do 8 skupin po 4 podle parcely

$$X = \mu_0 + \sum_{i=1}^4 \alpha_i V_i + \sum_{j=1}^8 \beta_j P_j$$

model3 = vynos ~ varianta + parcela

model4 = vynos ~ varianta \* parcela

# Vícenásobná ANOVA

Příklad: výnos plodiny ~ druh hnojiva + typ půdy

```
> vynosy<- data.frame(read.table("vynosy.txt", header=T))
```

$$X = \mu_0 + \alpha_1 V_1 + \alpha_2 V_2 + \alpha_3 V_3 + \alpha_4 V_4 + \epsilon$$

$$H_0 : \alpha_1 = \alpha_2 = \alpha_3 = \alpha_4 = 0$$

$$H_A : \exists i : \alpha_i \neq 0$$

```
> oneway1<- aov(vynos~varianta, data=vynosy)
```

```
> summary(oneway1)
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
varianta	3	0.21423	0.07141	25.79	3.29e-08 ***
Residuals	28	0.07752	0.00277		
<hr/>					

Signif. codes: 0 ‘\*\*\*’ 0.001 ‘\*\*’ 0.01 ‘\*’ 0.05 ‘.’ 0.1 ‘ ’ 1





```
> plot(oneway1)
```

# Vícenásobná ANOVA

Příklad: výnos plodiny ~ druh hnojiva + typ půdy

```
> vynosy<- data.frame(read.table("vynosy.txt", header=1)
```

$$X = \mu_0 + \alpha_1 V_1 + \alpha_2 V_2 + \alpha_3 V_3 + \alpha_4 V_4 + \epsilon$$



```
> plot(oneway1)
```

## Vícenásobná ANOVA

Příklad: výnos plodiny ~ druh hnojiva + typ půdy

$$X = \mu_0 + \beta_1 P_1 + \beta_2 P_2 + \beta_3 P_3 + \beta_4 P_4 + \beta_5 P_5 + \beta_6 P_6 + \beta_7 P_7 + \beta_8 P_8 + \epsilon$$

$$H_0 : \beta_1 = \dots = \beta_8 = 0$$

$$H_A : \exists j : \beta_j \neq 0$$

```
> oneway2<- aov(vynos~parcela, data=vynosy)
> summary(oneway2)
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
parcela	7	0.0274	0.003914	0.355	0.919
Residuals	24	0.2643	0.011015		

```
> plot(oneway2)
```

# Vícenásobná AN

Příklad: výnos plodiny

$$X = \mu_0 + \beta_1 P_1 + \beta_2 \cdot$$

$$H_0 : \beta_1 = \dots = \beta_8 =$$

$$H_A : \exists j : \beta_j \neq 0$$

```
> oneway2<- aov(vynos ~ parcela)
> summary(oneway2)
```


	Df	Sum Sq
parcela	7	0.021
Residuals	24	0.264

```
> plot(oneway2)
```

```
> shapiro.test(oneway2$residuals)
```

Shapiro-Wilk normality test

```
data: oneway2$residuals
W = 0.95112, p-value = 0.155
```



# Vícenásobná ANOVA

Příklad: výnos plodiny ~ druh hnojiva + typ půdy

$$X = \mu_0 + \sum_{i=1}^4 \alpha_i V_i + \sum_{j=1}^8 \beta_j P_j$$

```
> two way1 <- aov(vynos~vynos + parcela, data=vynosy)  
> summary(two way1)
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
varianta	3	0.21423	0.07141	29.92	9e-08 ***
parcela	7	0.02740	0.00391	1.64	0.179
Residuals	21	0.05012	0.00239		

```
> two way2 <- aov(vynos~vynos*parcela, data=vynosy)  
> summary(two way2)
```

	Df	Sum Sq	Mean Sq
varianta	3	0.21423	0.07141
parcela	7	0.02740	0.00391
varianta:parcela	21	0.05012	0.00239

# Neparametrická analýza rozptylu

Odezva  $X_1, X_2, \dots, X_n$  se neřídí normálním rozdělením => nelze použít ANOVA.

---

## Kruskal – Wallisův test

- Je neparametrickou obdobou analýzy rozptylu jednoduchého třídění.
- Slouží k ověření nulové hypotézy  $H_0$ , že  $k > 2$  nezávislých náhodných výběrů o rozsazích  $n_1, n_2, \dots, n_k$  pochází z jednoho základního souboru.
- Předpokládáme, že tyto náhodné výběry byly pořízeny ze základních souborů se spojitými distribučními funkcemi  $F_1(x), F_2(x), \dots, F_k(x)$ .
- Nulovou hypotézu  $H_0$  můžeme zapsat takto

$$H_0: F_1(x) = F_2(x) = \dots = F_k(x) \text{ pro všechna } x.$$

## Postup při stanovení testového kritéria:

- 1) Máme k dispozici  $k$  výběrových souborů o četnostech  $n_1, n_2, \dots, n_k$ .
- 2) Všechny výběrové soubory sloučíme do jediného souboru.
- 3) Každé hodnotě souboru přiřadíme vzestupně pořadové číslo, stejným hodnotám pak pořadí průměrné.
- 4) Následně sečteme pořadová čísla jednotlivých pozorování pro každý původní výběrový soubor zvlášť a získáme součty  $T_1, T_2, \dots, T_k$  ( $T_i ; i = 1, \dots, k$ , je tedy součet pořadových čísel pro  $i$ -tý výběr)

# Neparametrická analýza rozptylu

Odezva  $X_1, X_2, \dots, X_n$  se neřídí normálním rozdělením => nelze použít ANOVA.

## Kruskal – Wallisův test

Testová statistika má tvar:  
kde  $n = n_1 + n_2 + \dots + n_k$ .

$$KW = \frac{12}{n(n+1)} \sum_{i=1}^k \frac{T_i^2}{n_i} - 3(n+1)$$

Statistika KW má za platnosti  $H_0$  při  $n_i \rightarrow \infty$  asymptoticky  $\chi^2$  – rozdělení o  $k-1$  stupních volnosti.

Pokud  $KW > \chi_{\alpha}^2(n-1)$ , přijímáme hypotézu alternativní, podle které se hodnoty nejméně dvou porovnávaných výběrových souborů od sebe statisticky významně liší.

Jestliže se v posloupnosti zjištěných údajů vyskytnou shodné hodnoty, kterým se přiřazuje průměrné pořadí, je nutno hodnotu KW dělit korekčním faktorem

$$K = 1 - \frac{1}{n^3 - n} \sum_{j=1}^p (t_j^3 - t_j)$$

kde  $p$  je počet tříd se stejným pořadím a  $t_i$  počet pořadí v  $i$ -té třídě.

Opravené testové kritérium se stanoví jako  $KW_{opr} = \frac{KW}{K}$

# Neparametrická analýza rozptylu

MINITAB - Untitled

File Edit Data Calc Stat Graph Editor Tools Window Help

Session

Kruskal-Wallis Test: C1 versus C3

C1 N Median Rank Z  
1 2 16,95 7,0 0,78  
2 2 16,68 4,5 -0,52  
3 2 17,18 9,5 2,09  
4 2 16,47 3,0 -1,31  
5 2 16,55 3,5 -1,04  
Overall 10 5,5

H = 6,44 DF = 4 P = 0,169

\* NOTE \* One or more small samples

Basic Statistics ►  
Regression ►  
ANOVA ►  
DOF ►  
Control Charts ►  
Quality Tools ►  
Reliability/Survival ►  
Multivariate ►  
Time Series ►  
Tables ►

Nonparametrics ►  
1-Sample Sign...  
1-Sample Wilcoxon...  
Mann-Whitney...  
**Kruskal-Wallis...**  
Mood's Median Test...  
Friedman...  
Runs Test...  
Pairwise Averages...  
Pairwise Differences...  
Pairwise Slopes...

Kruskal-Wallis

Response: C1  
Factor: C3

Select OK Cancel

# Neparametrická analýza rozptylu

## Neparametrické metody mnohonásobného porovnávání.

---

### Neményiho metoda

- Předpokládáme tzv. „vyvážený pokusný plán“, tzn., že všech  $k$  výběrů má stejný rozsah (tedy  $n_1 = n_2 = \dots = n_k = N$ ).
- Spočítáme  $\frac{k(k-1)}{2}$  diferencí  $|T_i - T_j|$  které porovnáváme s kritickými hodnotami.
- Kritické hodnoty  $D_\alpha$  se hledají pro hladinu významnosti  $\alpha$ , pro  $k$  porovnávaných tříd a  $N$  opakování v každé třídě ( $n_1 = n_2 = \dots = n_k = N$ ).
- Je-li nějaká differenze větší nebo rovna kritické hodnotě  $D_\alpha$  pro Neményiho metodu, zamítá se hypotéza o neprůkaznosti diferenčního rozdílu, tzn. že  $i$ -tý a  $j$ -tý výběr pocházejí z téhož rozdělení.

# Neparametrická analýza rozptylu

## Neparametrické metody mnohonásobného porovnávání.

---

### Dunnova metoda

- Použijeme ji v případě „nevýváženého pokusného plánu“, tzn., že výběry nemají stejný rozsah (tedy nemusí být  $n_1 = n_2 = \dots = n_k$ ).
- Spočítáme  $\frac{k(k-1)}{2}$  differencí  $|T_i - T_j|$  které porovnáváme s kritickými hodnotami.

- Pokud pro nějakou diferenci platí  $|T_i - T_j| > u_\beta \sqrt{\frac{n(n-1)}{12} \left( \frac{1}{n_i} + \frac{1}{n_j} \right)}$

kde  $u_\beta$  je  $\beta$ - kvantil standardního normálního rozdělení,  $\beta = \frac{\alpha}{k(k-1)}$  ,

zamítáme na hladině významnosti  $\alpha$  hypotézu, že  $i$ -tý výběr (s rozsahem  $n_i$ ) a  $j$ -tý výběr (s rozsahem  $n_j$ ) pocházejí z téhož rozdělení.

-

## Neparametrická analýza rozptylu

Příklad: pevnost vláken ~ dodavatel (a, b, c)

```
> kruskal.test(pevnost ~ dodavatel, data = pevnost)
```

Kruskal-Wallis rank sum test

data: pevnost by dodavatel

Kruskal-Wallis chi-squared = 10.862, df = 2, p-value = 0.004379

	pevnost	dodavatel
1	18.3	a
2	17.5	a
3	20.3	a
4	19.9	a
5	19.8	a
6	18.7	a
7	18.3	b
8	18.6	b
9	19.2	b
10	19.7	b
11	21.1	b
12	20.2	b
13	21.0	c
14	21.4	c
15	21.2	c
16	22.2	c
17	23.1	c
18	22.1	c

```
> library(DescTools)
```

```
> NemenyiTest(pevnost ~ dodavatel, data = pevnost)
```

Nemenyi's test of multiple comparisons for independent samples (tukey)

	mean.rank.diff	pval
b-a	0	1.0000
c-a	9	0.0098 **
c-b	9	0.0098 **

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 '' 1

# Neparametrická analýza rozptylu

Odezva  $X_1, X_2, \dots, X_n$  se neřídí normálním rozdělením => nelze použít ANOVA.

## Friedmanův test

- Je neparametrickou obdobou analýzy rozptylu dvojného třídění (pro dva faktory - například pro jeden hlavní a druhý blokový).
- Předpokládejme, že máme měření  $y_{ij}$ , kde  $i$  je označení bloku,  $j$  je označení úrovně faktoru (ošetření). Pro každou dvojici  $(i,j)$  máme jedno měření.
- Označme

$k$  - počet úrovní faktoru

$n$  - počet bloků

$r_{ij}$  - pořadí naměřené hodnoty odezvy  $y_{ij}$  v bloku  $i$

$\bar{r}_{\cdot j}$  - průměrné pořadí odezvy při úrovni  $j$  přes všechny bloky

$\bar{r}$  - průměrné pořadí přes všechny úrovně a přes všechny bloky

$$\bar{r}_{\cdot j} = \frac{1}{n} \sum_{i=1}^n r_{ij} \quad \bar{r} = \frac{1}{nk} \sum_{i=1}^n \sum_{j=1}^k r_{ij}$$

Položme  $SS_t = n \sum_{j=1}^k (\bar{r}_{\cdot j} - \bar{r})^2$  a  $SS_e = \frac{1}{n(k-1)} \sum_{i=1}^n \sum_{j=1}^k (r_{ij} - \bar{r})^2$

Testová statistika má tvar  $Q = \frac{SS_t}{SS_e}$

(Pro velká  $n$  a  $k$  ( $n > 15$ ,  $k > 4$ ) má přibližně chí-kvadrát rozdělení o  $k-1$  stupních volnosti)

# Neparametrická analýza rozptylu

MINITAB - Untitled

File Edit Data Calc Graph Editor Tools Window Help

Basic Statistics ► Basic Statistics | Regression | ANOVA | DOE | Control Charts | Quality Tools | Reliability/Survival | Multivariate | Time Series | Tables

Nonparametrics ► 1-Sample Sign... | 1-Sample Wilcoxon... | Mann-Whitney... | Kruskal-Wallis... | Mood's Median Test... | Friedman... | Runs Test... | Pairwise Averages... | Pairwise Differences... | Pairwise Slopes...

Kruskal-Wallis Test

Kruskal-Wallis Test

C3	N	Median	Tables
1	2	16,	
2	2	16,	
3	2	17,	EDA
4	2	16,	
5	2	16,	Power and Sample Size
Overall	10	5,5	

H = 6,44 DF = 4 P = 0,169

\* NOTE \* One or more small samples

Friedman Test: C1 versus C3 blocked by C2

S = 1,50 DF = 2 P = 0,472

C3	N	Est	Median	Ranks
1	4	16,747	9,0	
2	4	16,460	6,0	
3	4	16,778	9,0	

Grand median = 16,662

Friedman

Response: C1  
Treatment: C3  
Blocks: C2

Store residuals  
 Store fits

Select      OK      Cancel